

Dernière exploration du `{tidyverse}` avec le package `{purrr}`

Marie VAUGOYEAU

02/05/2023

Contents

R-Ladies Paris	1
Introduction	1
Historique	1
Le format <code>tidy</code>	2
La syntaxe <code>tidyverse</code>	2
Les packages concernés	2
<code>{purrr}</code>	2
La différence avec les boucles	2
Premier exemple d'utilisation de <code>{purrr}</code> avec du texte	3
Deuxième exemple avec une fonction sur des <code>jdd</code>	5
Troisième exemple avec le traitement de colonnes d'un même <code>jdd</code>	9
Ressources intéressantes	23
En savoir un peu plus sur moi	23

R-Ladies Paris

R-Ladies Paris est une section locale de l'organisation mondiale R-Ladies Global qui promeut la diversité dans la communauté R et fournit un réseau de soutien convivial pour les passionnés du langage de programmation R dans le monde entier. N'hésitez pas à rejoindre le groupe sur Meetup afin d'être informés de nouveaux meetups organisés.

Introduction

Historique

Le `{tidyverse}` s'appelait encore le `hadleyverse` il y a quelques années, c'est-à-dire l'univers de Hadley pour Hadley Wickham son génial créateur.

Le but de Hadley est de rendre l'analyse données plus facile, plus rapide et surtout **plus fun** et je trouve que cela transparaît dans ses packages !

Le `{tidyverse}` c'est l'ensemble des packages open-source développé par Hadley et son équipe (Hadley travaille maintenant pour RStudio en plus de plusieurs universités) qui partagent la même philosophie, la même structure de données (le fameux format `tidy`) et la même syntaxe.

Le format `tidy`

Le format `tidy` repose sur la répétition des lignes des individus afin de limiter le nombre de colonnes.

Dans le plus stricte cas, le format `tidy` ne présente que 3 colonnes :

- __ Identification de l'individu, *par exemple* : `nom_du_pays`, `num_bague_identification`,...
- __ Variables mesurées, *par exemple* : `variable` peut prendre comme modalités `superficie`, `taille_population`, `PIB` ou `masse`, `taille`, `longueur_du_bec`...
- __ Valeur de la mesure. **Attention**, le format `tidy` ne supporte pas plusieurs type de données dans la même colonne !

La syntaxe `tidyverse`

Non détaillée ici, je vous invite à consulter le `tidyverse` style guide.

Les packages concernés

- __ `ggplot2` : Visulisation des données
- __ `dplyr` : Manipulation des données (filtrer, trier,...) à ne pas confondre avec `tidyr` qui manipule le format du jeu de données. Présenté le 7 février sur twitch.
- __ `tidyr` : Modification du format du jeu de données pour en faire un jeu de donnée `tidy`. Présenté le 7 février sur twitch.
- __ `readr` : Lecture rapide de fichiers de données format `csv` et autres. **Attention** : format `xslx` non pris en charge, il faut utiliser le package `readxl` qui fait partie du `tidyverse` au sens large mais qui n'est pas attaché par défaut quand on fait `library(tidyverse)`
- __ `purrr` : Permet le remplacement d'un grand nombre de boucles *Vu aujourd'hui*
- __ `tibble` : Format des données `tidy`
- __ `stringr` : Manipulation des chaînes de caractères. Présenté le 21 mars sur twitch.
- __ `forcats` : Manipulation des variables facteurs `factors`. Présenté le 21 mars sur twitch.
- __ `lubrdate` : Manipulation des dates. *Nouveau dans le {tidyverse}*

```
library(tidyverse)
```

`{purrr}`

La différence avec les boucles

L'itération c'est la répétition d'une action.

Elle peut-être réalisée avec une boucle `for()`, `if()` ou `while()` ou en utilisant la vectorisation.

Lors d'une boucle, les vérifications sont faites à chaque itération ce qui peut beaucoup augmenter le temps de calcul.

Il est aussi nécessaire d'initialiser l'objet contrairement à l'utilisation des vecteurs.

Exemple : création d'un objet contenant les doubles de 1 à 10

```
objet <- 2

for (i in (2:10)){
  objet[i] <- i*2
}
```

Le même objet peut être créé avec la vectorisation qui est la base dans R.

```
vecteur <- (1:10)*2
identical(objet, vecteur)
```

```
## [1] TRUE
```

Premier exemple d'utilisation de {purrr} avec du texte

Utilisation du début du livre, Les mémoires d'Hadrien de Marguerite Yourcenar.

```
hadrien <- "Je suis descendu ce matin chez mon médecin Hermogène, qui vient de rentrer à la Villa après
# séparer les phrases
paragraphe <- str_split(hadrien, "\\.")
# afficher la longueur
str_length(paragraphe)
```

```
## [1] 506
```

```
# totale
map(.x = paragraphe, .f = ~ str_length(.x))
```

```
## [[1]]
## [1] 120 103 84 177 0
```

```
# beaucoup de fonctions sont prévues pour la vectorisation et peuvent fonctionner sans mapping
hadrien %>%
  str_split("\\.", simplify = TRUE) %>%
  str_length()
```

```
## [1] 120 103 84 177 0
```

```
# détacher par phrases et par mots
str_split(hadrien, " ", simplify = TRUE) %>% length()
```

```
## [1] 88
```

```
str_split(paragraphe, " ", simplify = TRUE) %>% length()
```

```
## [1] 92
```

```
str_split(paragraphe, " ", simplify = TRUE)
```

```
## [1,] [2,] [3,] [4,] [5,] [6,] [7,] [8,]
## [1,] "c(\"Je\" \"suis\" \"descendu\" \"ce\" \"matin\" \"chez\" \"mon\" \"médecin\"
## [9] [10] [11] [12] [13] [14] [15] [16] [17]
## [1,] \"Hermogène,\" \"qui\" \"vient\" \"de\" \"rentrer\" \"à\" \"la\" \"Villa\" \"après\"
## [18] [19] [20] [21] [22] [23] [24] [25] [26]
## [1,] \"un\" \"assez\" \"long\" \"voyage\" \"en\" \"Asie\\\", \"\\\" \"L'examen\" \"devait\"
## [27] [28] [29] [30] [31] [32] [33] [34] [35]
## [1,] \"se\" \"faire\" \"à\" \"jeun\" \":\" \"nous\" \"avons\" \"pris\" \"rendez-vous\"
## [36] [37] [38] [39] [40] [41] [42] [43] [44]
## [1,] \"pour\" \"les\" \"premières\" \"heures\" \"de\" \"la\" \"matinée\\\", \"\\\" \"Je\"
## [45] [46] [47] [48] [49] [50] [51] [52] [53] [54]
## [1,] \"me\" \"suis\" \"couché\" \"sur\" \"un\" \"lit\" \"après\" \"m'êtr\" \"dépouillé\" \"de\"
## [55] [56] [57] [58] [59] [60] [61] [62] [63]
## [1,] \"mon\" \"manteau\" \"et\" \"de\" \"ma\" \"tunique\\\", \"\\\" \"Je\" \"t'épargne\"
## [64] [65] [66] [67] [68] [69] [70] [71]
## [1,] \"des\" \"détails\" \"qui\" \"te\" \"seraient\" \"aussi\" \"désagréables\" \"qu'à\"
## [72] [73] [74] [75] [76] [77] [78] [79] [80]
## [1,] \"moimême,\" \"et\" \"la\" \"description\" \"du\" \"corps\" \"d'un\" \"homme\" \"qui\"
## [81] [82] [83] [84] [85] [86] [87] [88] [89]
## [1,] \"avance\" \"en\" \"âge\" \"et\" \"s'apprête\" \"à\" \"mourir\" \"d'une\" \"hydropisie\"
## [90] [91] [92]
## [1,] \"du\" \"cœur\\\", \"\\n\\\"\\\"\"
```

```
# changer de profondeur dans l'objet grâce à `_depth`
map(
  .x = paragraphe,
  .f = ~ str_split(.x, " ")
) %>%
  map_depth(2, length)
```

```
## [[1]]
## [[1]][[1]]
## [1] 23
##
## [[1]][[2]]
## [1] 19
##
## [[1]][[3]]
## [1] 18
##
## [[1]][[4]]
## [1] 31
##
## [[1]][[5]]
## [1] 1
```

```
# utilisation de `map2()` lorsque deux listes sont intégrée et `pmap()` lorsqu'il y a plus
map2_chr(
  .x = c("Alice", "Marc", "Julie", "Charlie"),
  .y = c("plage", "montagne", "campagne", "cuisine"),
```

```
.f = ~ str_c(.x, " va à la ", .y)
)
```

```
## [1] "Alice va à la plage"      "Marc va à la montagne"
## [3] "Julie va à la campagne"   "Charlie va à la cuisine"
```

```
# type d'objet produit par map -> une liste par défaut
map2(
  .x = c("Alice", "Marc", "Julie", "Charlie"),
  .y = c("plage", "montagne", "campagne", "cuisine"),
  ~ str_c(.x, " va à la ", .y)
) %>%
class()
```

```
## [1] "list"
```

```
# possibilité de changer le type de sortie avec _chr ou _dbl...
map2_chr(
  .x = c("Alice", "Marc", "Julie", "Charlie"),
  .y = c("plage", "montagne", "campagne", "cuisine"),
  ~ str_c(.x, " va à la ", .y)
) %>%
class()
```

```
## [1] "character"
```

```
map2_chr(
  .x = c("Alice", "Marc", "Julie", "Charlie"),
  .y = c("plage", "montagne", "campagne", "cuisine"),
  ~ str_c(.x, " va à la ", .y)
)
```

```
## [1] "Alice va à la plage"      "Marc va à la montagne"
## [3] "Julie va à la campagne"   "Charlie va à la cuisine"
```

Deuxième exemple avec une fonction sur des jdd

Commençons par voir la fonction `across()` du package `{dplyr}` qui permet d'appliquer une ou plusieurs fonctions sur des colonnes multiples.

```
# calcul des moyennes de sepal_length
iris %>%
  summarise(sepal_length_moyenne = mean(Sepal.Length))
```

```
##   sepal_length_moyenne
## 1                5.843333
```

```
# application à toutes les colonnes numériques
iris %>%
  summarise(
    across(
      .cols = where(is.numeric),
      .fns = list(moyenne = ~ mean(.x, na.rm = TRUE), minimum = min, maximum = max),
      .names = "{col}_{fn}"
    )
  )
)
```

```
##   Sepal.Length_moyenne Sepal.Length_minimum Sepal.Length_maximum
## 1          5.843333          4.3          7.9
##   Sepal.Width_moyenne Sepal.Width_minimum Sepal.Width_maximum
## 1          3.057333          2          4.4
##   Petal.Length_moyenne Petal.Length_minimum Petal.Length_maximum
## 1          3.758          1          6.9
##   Petal.Width_moyenne Petal.Width_minimum Petal.Width_maximum
## 1          1.199333          0.1          2.5
```

Réalisation sur différentes tables de données grâce à la fonction `map()` de `{purrr}`.

```
# travail sur les jdd de données iris, mtcars et women
map(
  .x = list(iris, mtcars, women),
  .f = ~ summarise(
    .x,
    across(
      .cols = where(is.numeric),
      .fns = list(moyenne = ~ mean(.x, na.rm = TRUE), minimum = min, maximum = max),
      .names = "{col}_{fn}"
    )
  )
)
```

```
## [[1]]
##   Sepal.Length_moyenne Sepal.Length_minimum Sepal.Length_maximum
## 1          5.843333          4.3          7.9
##   Sepal.Width_moyenne Sepal.Width_minimum Sepal.Width_maximum
## 1          3.057333          2          4.4
##   Petal.Length_moyenne Petal.Length_minimum Petal.Length_maximum
## 1          3.758          1          6.9
##   Petal.Width_moyenne Petal.Width_minimum Petal.Width_maximum
## 1          1.199333          0.1          2.5
##
## [[2]]
##   mpg_moyenne mpg_minimum mpg_maximum cyl_moyenne cyl_minimum cyl_maximum
## 1   20.09062   10.4      33.9    6.1875      4          8
##   disp_moyenne disp_minimum disp_maximum hp_moyenne hp_minimum hp_maximum
## 1   230.7219    71.1      472   146.6875    52       335
##   drat_moyenne drat_minimum drat_maximum wt_moyenne wt_minimum wt_maximum
## 1    3.596563    2.76      4.93    3.21725    1.513     5.424
##   qsec_moyenne qsec_minimum qsec_maximum vs_moyenne vs_minimum vs_maximum
## 1   17.84875    14.5      22.9    0.4375      0          1
```

```
##   am_moyenne am_minimum am_maximum gear_moyenne gear_minimum gear_maximum
## 1    0.40625      0         1    3.6875      3         5
##   carb_moyenne carb_minimum carb_maximum
## 1    2.8125      1         8
##
## [[3]]
##   height_moyenne height_minimum height_maximum weight_moyenne weight_minimum
## 1             65             58             72      136.7333      115
##   weight_maximum
## 1             164
```

```
# ajout des noms des jeux de données
map(
  .x = list(iris, mtcars, women),
  .f = ~ summarise(
    .x,
    across(
      .cols = where(is.numeric),
      .fns = list(moyenne = ~ mean(.x, na.rm = TRUE), minimum = min, maximum = max),
      .names = "{col}_{fn}"
    )
  )
) %>%
  set_names(c("iris", "mtcars", "women"))
```

```
## $iris
##   Sepal.Length_moyenne Sepal.Length_minimum Sepal.Length_maximum
## 1    5.843333      4.3      7.9
##   Sepal.Width_moyenne Sepal.Width_minimum Sepal.Width_maximum
## 1    3.057333      2      4.4
##   Petal.Length_moyenne Petal.Length_minimum Petal.Length_maximum
## 1    3.758      1      6.9
##   Petal.Width_moyenne Petal.Width_minimum Petal.Width_maximum
## 1    1.199333      0.1      2.5
##
## $mtcars
##   mpg_moyenne mpg_minimum mpg_maximum cyl_moyenne cyl_minimum cyl_maximum
## 1    20.09062    10.4    33.9    6.1875      4      8
##   disp_moyenne disp_minimum disp_maximum hp_moyenne hp_minimum hp_maximum
## 1    230.7219     71.1    472    146.6875     52    335
##   drat_moyenne drat_minimum drat_maximum wt_moyenne wt_minimum wt_maximum
## 1    3.596563     2.76     4.93     3.21725     1.513     5.424
##   qsec_moyenne qsec_minimum qsec_maximum vs_moyenne vs_minimum vs_maximum
## 1    17.84875     14.5     22.9     0.4375      0      1
##   am_moyenne am_minimum am_maximum gear_moyenne gear_minimum gear_maximum
## 1    0.40625      0         1    3.6875      3         5
##   carb_moyenne carb_minimum carb_maximum
## 1    2.8125      1         8
##
## $women
##   height_moyenne height_minimum height_maximum weight_moyenne weight_minimum
## 1             65             58             72      136.7333      115
##   weight_maximum
## 1             164
```

```

# format tableau croisé
map(
  .x = list(iris, mtcars, women),
  .f = ~ summarise(
    .x,
    across(
      .cols = where(is.numeric),
      .fns = list(moyenne = ~ mean(.x, na.rm = TRUE), minimum = min, maximum = max),
      .names = "{col}_{fn}"
    )
  )
) %>%
set_names(c("iris", "mtcars", "women")) %>%
map(
  .f = ~ pivot_longer(
    .x,
    cols = everything(),
    names_to = c("measure", ".value"),
    names_pattern = "(.+)_(.+)"
  )
)

```

```

## $iris
## # A tibble: 4 x 4
##   measure      moyenne minimum maximum
##   <chr>      <dbl>    <dbl>    <dbl>
## 1 Sepal.Length  5.84      4.3      7.9
## 2 Sepal.Width   3.06      2        4.4
## 3 Petal.Length  3.76      1        6.9
## 4 Petal.Width   1.20      0.1      2.5
##
## $mtcars
## # A tibble: 11 x 4
##   measure moyenne minimum maximum
##   <chr>      <dbl>    <dbl>    <dbl>
## 1 mpg      20.1     10.4     33.9
## 2 cyl       6.19      4        8
## 3 disp     231.     71.1    472
## 4 hp       147.     52     335
## 5 drat      3.60     2.76    4.93
## 6 wt        3.22     1.51    5.42
## 7 qsec     17.8     14.5    22.9
## 8 vs        0.438    0        1
## 9 am        0.406    0        1
## 10 gear     3.69      3        5
## 11 carb     2.81      1        8
##
## $women
## # A tibble: 2 x 4
##   measure moyenne minimum maximum
##   <chr>      <dbl>    <dbl>    <dbl>
## 1 height    65      58      72
## 2 weight   137.    115    164

```


Troisième exemple avec le traitement de colonnes d'un même jdd

Exemple : avec les données {*anscombe*}

C'est un jeu de données de "4" groupes pour lesquelles les propriétés statistiques simple (moyennes, variance, corrélation, régression linéaire) sont similaire alors que les données sont très différentes.

```
anscombe
```

```
##      x1 x2 x3 x4      y1      y2      y3      y4
## 1   10 10 10  8   8.04 9.14  7.46  6.58
## 2    8  8  8  8   6.95 8.14  6.77  5.76
## 3   13 13 13  8   7.58 8.74 12.74  7.71
## 4    9  9  9  8   8.81 8.77  7.11  8.84
## 5   11 11 11  8   8.33 9.26  7.81  8.47
## 6   14 14 14  8   9.96 8.10  8.84  7.04
## 7    6  6  6  8   7.24 6.13  6.08  5.25
## 8    4  4  4 19   4.26 3.10  5.39 12.50
## 9   12 12 12  8  10.84 9.13  8.15  5.56
## 10   7  7  7  8   4.82 7.26  6.42  7.91
## 11   5  5  5  8   5.68 4.74  5.73  6.89
```

```
# réalisation d'une régression linéaire
```

```
## simple
```

```
lm(y1 ~ x1, data = anscombe) %>%
  summary()
```

```
##
## Call:
## lm(formula = y1 ~ x1, data = anscombe)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.92127 -0.45577 -0.04136  0.70941  1.83882
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   3.0001      1.1247   2.667  0.02573 *
## x1             0.5001      0.1179   4.241  0.00217 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.237 on 9 degrees of freedom
## Multiple R-squared:  0.6665, Adjusted R-squared:  0.6295
## F-statistic: 17.99 on 1 and 9 DF, p-value: 0.00217
```

```
## sur toutes les colonnes
```

```
map2(
  .x = c("x1", "x2", "x3", "x4"),
  .y = c("y1", "y2", "y3", "y4"),
  .f = ~ lm(get(.y) ~ get(.x), data = anscombe) %>% summary()
)
```

```
## [[1]]
```

```
##
## Call:
## lm(formula = get(.y) ~ get(.x), data = anscombe)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.92127 -0.45577 -0.04136  0.70941  1.83882
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   3.0001      1.1247   2.667  0.02573 *
## get(.x)        0.5001      0.1179   4.241  0.00217 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.237 on 9 degrees of freedom
## Multiple R-squared:  0.6665, Adjusted R-squared:  0.6295
## F-statistic: 17.99 on 1 and 9 DF, p-value: 0.00217
##
##
## [[2]]
##
## Call:
## lm(formula = get(.y) ~ get(.x), data = anscombe)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.9009 -0.7609  0.1291  0.9491  1.2691
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   3.001      1.125   2.667  0.02576 *
## get(.x)        0.500      0.118   4.239  0.00218 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.237 on 9 degrees of freedom
## Multiple R-squared:  0.6662, Adjusted R-squared:  0.6292
## F-statistic: 17.97 on 1 and 9 DF, p-value: 0.002179
##
##
## [[3]]
##
## Call:
## lm(formula = get(.y) ~ get(.x), data = anscombe)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.1586 -0.6146 -0.2303  0.1540  3.2411
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   3.0025      1.1245   2.670  0.02562 *
## get(.x)        0.4997      0.1179   4.239  0.00218 **
```

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.236 on 9 degrees of freedom
## Multiple R-squared:  0.6663, Adjusted R-squared:  0.6292
## F-statistic: 17.97 on 1 and 9 DF,  p-value: 0.002176
##
##
## [[4]]
##
## Call:
## lm(formula = get(.y) ~ get(.x), data = anscombe)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.751 -0.831  0.000  0.809  1.839
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   3.0017     1.1239   2.671  0.02559 *
## get(.x)       0.4999     0.1178   4.243  0.00216 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.236 on 9 degrees of freedom
## Multiple R-squared:  0.6667, Adjusted R-squared:  0.6297
## F-statistic:   18 on 1 and 9 DF,  p-value: 0.002165
```

```
## avec l'utilisation de la fonction glue
```

```
library(glue)
library(glue)
glue("x{1:4}")
```

```
## x1
## x2
## x3
## x4
```

```
## utilisation de set_names() pour le nom des jdd
```

```
map2(
  .x = c(glue("x{1:4}")),
  .y = c(glue("y{1:4}")),
  .f = ~ lm(get(.y) ~ get(.x), data = anscombe) %>% summary()
) %>%
  set_names(glue("colonnes finissants par {1:4}"))
```

```
## $'colonnes finissants par 1'
##
## Call:
## lm(formula = get(.y) ~ get(.x), data = anscombe)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
```


```

## -1.92127 -0.45577 -0.04136 0.70941 1.83882
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)   3.0001      1.1247   2.667 0.02573 *
## get(.x)        0.5001      0.1179   4.241 0.00217 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.237 on 9 degrees of freedom
## Multiple R-squared:  0.6665, Adjusted R-squared:  0.6295
## F-statistic: 17.99 on 1 and 9 DF, p-value: 0.00217
##
##
## $'colonnes finissants par 2'
##
## Call:
## lm(formula = get(.y) ~ get(.x), data = anscombe)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.9009 -0.7609  0.1291  0.9491  1.2691
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)   3.001      1.125   2.667 0.02576 *
## get(.x)        0.500      0.118   4.239 0.00218 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.237 on 9 degrees of freedom
## Multiple R-squared:  0.6662, Adjusted R-squared:  0.6292
## F-statistic: 17.97 on 1 and 9 DF, p-value: 0.002179
##
##
## $'colonnes finissants par 3'
##
## Call:
## lm(formula = get(.y) ~ get(.x), data = anscombe)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.1586 -0.6146 -0.2303  0.1540  3.2411
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)   3.0025      1.1245   2.670 0.02562 *
## get(.x)        0.4997      0.1179   4.239 0.00218 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.236 on 9 degrees of freedom
## Multiple R-squared:  0.6663, Adjusted R-squared:  0.6292
## F-statistic: 17.97 on 1 and 9 DF, p-value: 0.002176

```


```
##
##
## $'colonnes finissants par 4'
##
## Call:
## lm(formula = get(.y) ~ get(.x), data = anscombe)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.751 -0.831  0.000  0.809  1.839
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   3.0017     1.1239   2.671  0.02559 *
## get(.x)       0.4999     0.1178   4.243  0.00216 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.236 on 9 degrees of freedom
## Multiple R-squared:  0.6667, Adjusted R-squared:  0.6297
## F-statistic:    18 on 1 and 9 DF,  p-value: 0.002165

# vérification grâce à un graphique
ggplot(anscombe) +
  aes(x = x1, y = y1) +
  geom_point() +
  geom_abline(slope = 0.5, intercept = 3, color = "blue") +
  theme_classic()
```




```
## sur toutes les colonnes
purrr::map2(
  .x = c(glue("x{1:4}")),
  .y = c(glue("y{1:4}")),
  .f = ~ ggplot(anscombe) +
    aes(x = get(.x), y = get(.y)) +
    geom_point() +
    geom_abline(slope = 0.5, intercept = 3, color = "blue") +
    theme_classic()
)
```


```
## [[1]]
```




```
##  
## [[2]]
```



```
##  
## [[3]]
```





```
##  
## [[4]]
```




```
## modification des noms des axes
purrr::map2(
  .x = c(glue("x{1:4}")),
  .y = c(glue("y{1:4}")),
  .f = ~ ggplot(anscombe) +
    aes(x = get(.x), y = get(.y)) +
    geom_point() +
    geom_abline(slope = 0.5, intercept = 3, color = "blue") +
    labs(x = .x, y = .y) +
    theme_classic()
)
```


```
## [[1]]
```




```
##  
## [[2]]
```



```
##  
## [[3]]
```



```
##  
## [[4]]
```



```
## enregistrement automatique des graphiques générés
purrr::map2(
  .x = c(glue("x{1:4}")),
  .y = c(glue("y{1:4}")),
  .f = ~ ggplot(anscombe) +
    aes(x = get(.x), y = get(.y)) +
    geom_point() +
    geom_abline(slope = 0.5, intercept = 3, color = "blue") +
    labs(x = .x, y = .y) +
    theme_classic()
) %>%
purrr::map2(
  .y = c(glue("img/x{1:4}y{1:4}.png")),
  .f = ~ ggsave(plot = .x, filename = .y, width = 2, height = 2)
)
```

```
## [[1]]
## [1] "img/x1y1.png"
##
## [[2]]
## [1] "img/x2y2.png"
##
## [[3]]
## [1] "img/x3y3.png"
##
## [[4]]
```

```
## [1] "img/x4y4.png"
```

Ressources intéressantes

- _ le cheatsheet de {purrr}
- _ la vignette de {purrr}
- _ La page d'itération dans l'e-book R for Data Science

En savoir un peu plus sur moi

Bonjour, Je suis Marie Vaugoyeau et je suis disponible pour des **missions en freelance d'accompagnement à la formation** à R et à l'analyse de données et/ou en **programmation** (reprise de scripts, bonnes pratiques de codage, développement de package).

Ayant un **bagage recherche en écologie**, j'ai accompagné plusieurs chercheuses en biologie dans leurs analyses de données mais je suis ouverte à d'autres domaines.

Vous pouvez retrouver mes offres ici.

En plus de mes missions de consulting je diffuse mes savoirs en R et analyse de données sur plusieurs plateformes :

- J'ai écrit un **livre** aux éditions ENI
- Tous les mois je fais un **live sur Twitch** pour parler d'un package de R, d'une analyse
- Je rédige une **newsletter** de manière irrégulière pour parler de mes **inspirations** et transmettre **des trucs et astuces sur R**. Pour s'y inscrire, c'est par là. J'ai aussi un **blog**, en PLS en ce moment, qu'il faut que je reprenne.

Pour en savoir encore un peu plus sur moi, il y a LinkedIn et pour retrouver tous ces liens et plus encore, c'est ici

N'hésitez pas à me contacter sur marie.vaugoyeau@gmail.com !

Bonne journée

Marie